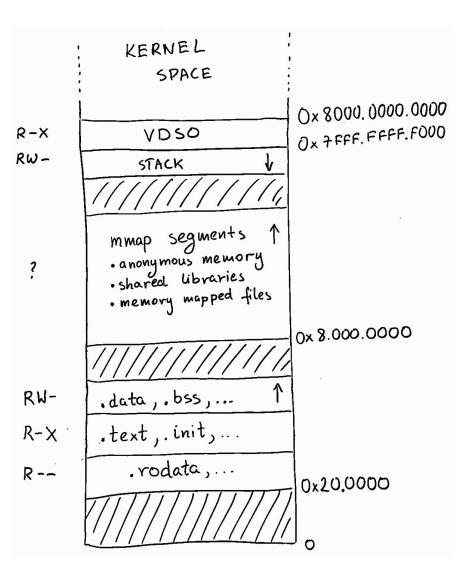
Struktura jądra UNIX

Wykład 10 i 11: Procesy

Przestrzeń adresowa procesu: FreeBSD x86-64

Jądro żyje w górnej połowie przestrzeni adresowej każdego procesu!

- Mapa pamięci procesu:
 procstat -v
- Pod koniec BSS koniec programu (ang. segment break).
- Sterta przydzielana mmap.
- Tyle stosów ile wątków!
- Biblioteka współdzielona jądra <u>vdso</u>.



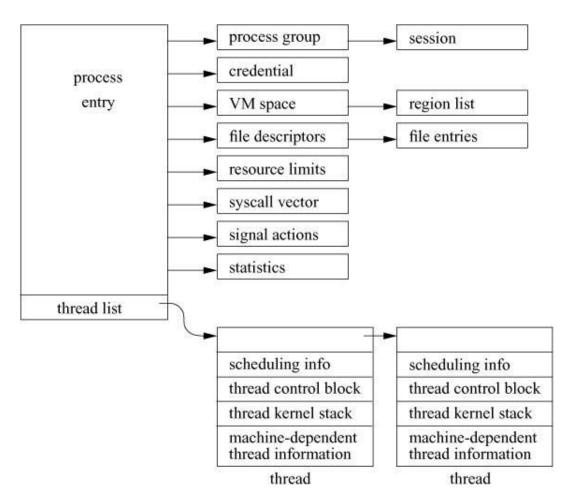
FreeBSD: Zasoby procesu

Proces <u>proc</u> posiada co najmniej jeden aktywny wątek <u>thread</u>.

Rozróżnienie między zasobami, a kontekstami wykonania.

<u>pcb</u> (process control block)to sprzętowy kontekst wątku(historyczna nazwa)

Model wątków 1:1.



FreeBSD: Stan procesu vs. stan wątku

Procesy i wątki to różne byty! Stany procesu:

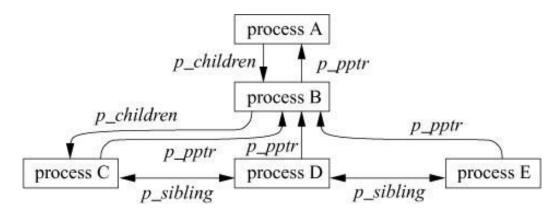
Stan	Opis
PRS_NEW	proces jest w trakcie tworzenia
PRS_NORMAL	istnieje co najmniej jeden wątek, który jest w stanie RUNNABLE, SLEEPING lub STOPPED
PRS_ZOMBIE	proces jest w trakcie odśmiecania

Dodatkowo mamy cały szereg flag w <u>p_flag</u> rejestrujących pewne fakty o procesie na potrzeby implementacji wywołań systemowych (np. <u>P_EXEC</u> dla ptrace).

Ciekawsze zasoby procesu proc

- Tożsamość <u>p_ucred</u> (identyfikatory)
- Tabela deskryptorów plików i bieżący katalog p fd
- Statystyki <u>p stats</u> (zużyty czas i zasoby)
- Limity na zasoby <u>p_limit</u> (pamięć, czas procesora, ...)
- Maski sygnałów i bieżące akcje <u>p sigacts</u>
- Opis przestrzeni adresowej <u>p_vmspace</u>
- Wektor wywołań systemowych <u>p_sysent</u>
- V-węzęł pliku wykonywalnego <u>p textvp</u>
- Grupa procesów p pgrp
- Czasomierze <u>p realtimer</u> i <u>p itimers</u>

FreeBSD: Hierarchia procesów



W nagłówku pliku <u>proc.h</u> mowa o konwencji zakładania blokad:

- (c) proc::p_mtx (d) allproc_lock (e) proctree_lock
- (f) session::s_mtx (g) pgrp::pg_mtx.

Każdy proces jest liście **allproc** albo **zombproc** chronionej blokadą **allproc_lock** (sx). Kiedy trawersujemy drzewo należy trzymać blokadę **proctree_lock**. Kiedy członków grupy to **pg_mtx**.

Komentarz: Dodatkowo każdy proces posiada żniwiarza (ang. reaper).

FreeBSD: Tworzenie procesów

- 1. **«fork»** kompletna (?) kopia procesu
- 2. **«vfork»** nie klonuje przestrzeni adresowej, rodzic jest wznawiany wtw. gdy dziecko zawoła execve lub exit
- 3. **"rfork"** tworzy proces potomny, który współdzieli pewne zasoby z procesem tworzącym (RFMEM, RFSIGSHARE)

Używając jądra Linux tworzymy nowe procesy przy pomocy clone(2) → brak wyraźnego podziału na procesy i wątki.

We FreeBSD osobne wywołania systemowe: thr_exit(2), thr_kill(2) i uniwersalny mechanizm konstrukcji środków synchronizacji: umtx_op(2).

fork1: tworzenie nowego procesu

Po przydzieleniu pamięci na strukturę proc (newproc):

- Tworzymy nowy wątek <u>thread_alloc</u> (td2).
- 2. Podłączamy wątek do procesu <u>proc_linkup</u>.
- 3. Klonujemy przestrzeń adresową <u>vmspace fork</u> (**vm2**).
- 4. Współdzielimy kredencjały z rodzicem.
- 5. Inicjujemy księgowanie zasobów racct proc fork.

Tak uzbrojeni wchodzimy do <u>do fork</u>, gdzie:

- 1. Kopiujemy pola p_startcopy...p_endcopy z rodzica, np. nazwę procesu, priorytet, ograniczenie na zużycie czasu.
- 2. Czyścimy pola p_startzero...p_endzero: np. zużycie zasobów, ustawienia czasomierzy.

do fork: główna procedura klonowania procesu

- 1. Stan procesu ustala na PRS_NEW.
- 2. Przydziela nowy identyfikator <u>fork_findpid</u>.
- 3. Wstawienia proces na listę wszystkich procesów allproc oraz odpowiedniego kubełka tablicy mieszającej <u>pidhashtbl</u>.
- 4. Kopiuje tablicę deskryptorów <u>fdcopy</u>.
- 5. Kopiuje ustawienia planisty sched_fork (w
- 6. Klonuje ustawienia sygnałów <u>sigacts copy</u>.
- 7. Kopiuje lub zeruje limity <u>lim fork</u> i statystyki <u>pstats fork</u>.
- 8. Wstawia proces do grupy procesów rodzica p_pgrp i podłącza proces potomny pod rodzica p_pptr.
- 9. Przygotowuje przestrzeń adresową i kontekst na pierwsze wejście nowego wątku <u>vm_forkproc</u> (kopiuje stos, fork ma zwrócić zero).
- 10. Oznacza proces PRS_NORMAL i dodaje wątek do planisty <u>sched_add</u>.

Szybkie wyszukiwanie identyfikatorów pid

Żeby przyspieszyć wyszukiwanie procesów względem numeru pid uciekamy się do dobrze znanego pomysłu → kubełki procesów: pidhashtbl[] i pidhashtbl_lock[].

Problem: Jak szybko znaleźć nieużywany numer pid?

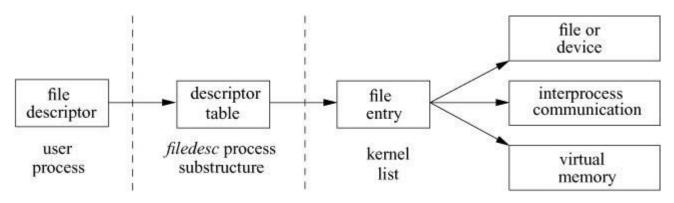
Uwaga! We FreeBSD §4.5 nieaktualny opis!

Trzymamy bitmapę proc_id_pidmap zajętych numerów pid. Podobnie dla grpid i sessid. Procedura <u>fork_findpid</u> przeszukuje ją używając generatora liczb pseudolosowych.

Do randomized PIDs bring more security?

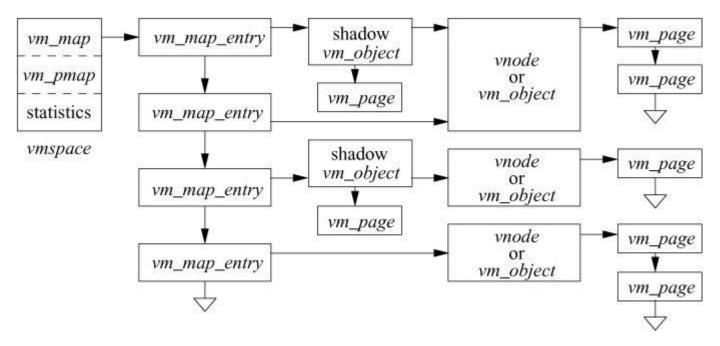
Kopiowanie tablicy deskryptorów filedesc(9)

Kopiowanie tablicy deskryptorów (<u>fdcopy</u>) inkrementuje licznik referencji (<u>fhold</u>) wszystkim plikom (<u>file</u>), na które wskazują deskryptory plików.



Innymi słowy kopiujemy referencje do otwartych plików, a nie struktury opisujące otwarte pliki. Zatem współdzielimy kursory plików (f_offset) i flagi (f_flags).

Klonowanie przestrzeni adresowej



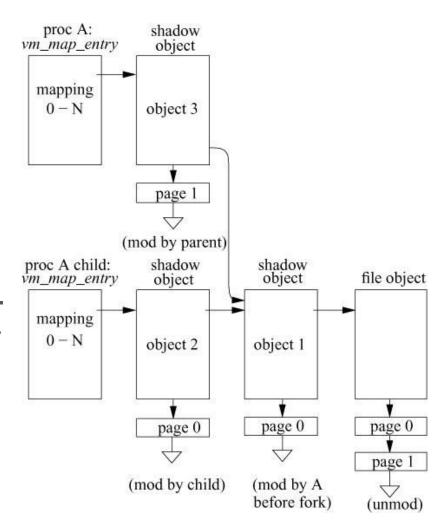
Sklonujemy tylko i wyłącznie segmenty (vm_map_entry) bez kopiowania ich zawartości (vm_object).

Zawartość będzie trzeba oznaczyć tak, żeby zapis wygenerował kopię modyfikowanej strony (ang. copy on write).

Obiekty przesłaniające i kopiowanie przy zapisie

Każdy obiekt zawiera strony, które zmodyfikował względem kolejnego w łańcuchu obiektu wspierającego.

Po fork tworzymy obiekty przesłaniające w obu procesach. W tablicy stron pmap oznaczamy wszystkie strony read-only. Obsługa błędy strony skopiuje stronę i zmieni uprawnienia.



FreeBSD: Kończenie pracy procesów

Faktycznie tylko dwa sposoby na zakończenie procesu:

- normalne zakończenie pracy (<u>exit</u>)
- otrzymanie sygnału uśmiercającego (awaria lub <u>kill</u>)

Można oczekiwać na zakończenie jednego z bezpośrednich potomków wait4(2). Odbierzemy informację czy zakończył się normalnie, z błędem, czy w wyniku awarii. Można też odczytać zużycie zasobów rusage (czas CPU, pamięć, operacje I/O). W przypadku wait6(4) możemy też dostać siginfo_t (np. błędny adres wiodący do SIGSEGV).

exit1: Śmierć procesu (1)

- Najpierw należy zabić pozostałe wątki w procesie:
 - a. wątek wchodzący z przestrzeni użytkownika do przestrzeni jądra zostanie przekierowany do thread_exit
 - b. wątki w jądrze zamiast pójść spać wrócą z EINTR lub EAGAIN
 - c. **pytanie:** co z tymi które śpią? <u>thread_suspend_check</u>
- 2. Potem zwolnić zasoby procesu:
 - a. anulowanie terminów czasomierzy
 - b. zwolnienie przestrzeni adresowej <u>vmspace exit</u>
 - c. zamknięcie wszystkich deskryptorów plików <u>fdescfree</u>
- 3. I wreszcie zatroszczyć się o zależne procesy:
 - a. wycofanie się z roli lidera sesji <u>killjobc</u>
 - b. zabicie zatrzymanych lub śledzonych procesów potomnych
 - c. przepięcie procesów potomnych pod żniwiarza proc reparent

exit1: Śmierć procesu (2)

Zanim exit1 zakończy działanie musi:

- 1. Zapisać kod wyjścia procesu w <u>p_xexit</u>.
- 2. Dodać statystyki procesu z <u>p ru</u> do statystyk rodzica <u>ruadd</u>.
- 3. Wypiąć się z listy procesów (zostaje w <u>pidhashtbl</u>).
- 4. Wybudzić rodzica czekającego na potomków wakeup.
- 5. Wysłać sygnał SIGCHLD do rodzica childproc exited.
- 6. Przejść w stan PRS_ZOMBIE.

Ostatni wątek należący do procesu popełnia thread_exit, a w rezultacie sched_throw, które wybiera kolejny proces do uruchomienia choosethread i porzuca kontekst bieżącego wątku cpu_throw na rzecz nowo wybranego.

Stan ZOMBIE czyli życie po śmierci

Proces w stanie ZOMBIE jest nadal w kubełku pidhashtbl i na liście potomków procesu p_children.

Wywołanie systemowe wait* ostatecznie trafia do <u>kern_wait6</u>. Jeśli na liście p_children procedura <u>proc_to_reap</u> znajdzie zombiaka to przystępujemy do pogrzebu <u>proc_reap</u>:

- Informacje p_ru, p_xexit, p_xsigno i pochodne są przeznaczone do skopiowania do user-space.
- Usuwamy proces z listy potomków i pidhashtbl.
- Proces opuszcza grupę procesów <u>leavepgrp</u>.
- Zwalniamy identyfikator procesu <u>proc_id_clear</u>.
- Zwalniamy pozostałe elementy struktury proc i ją samą.

execve(2): Ładowanie programów

Używamy pary fork i execve, alternatywnie posix spawn.

- 1. Ustalamy zasoby widoczne dla uruchamianego programu:
 - a. deskryptory nieoznaczone FD_CLOEXEC → przechodzą
 - b. sygnały: ignorowane → przechodzą, wyłapywane → ustawiane SIG_DFL
 - c. katalog główny i roboczy → przechodzą
 - d. przestrzeń adresowa → całkowicie wymazywana
- 2. Wołamy execve(path, argv, envp):
 - a. path → ścieżka absolutna
 - b. argv → lista parametrów
 - c. envp → lista zmiennych środowiskowych w formacie "key=value".

Pliku programu nie można modyfikować → ETXTBSY!

Niektórzy (z M\$) twierdzą, że fork to zły pomysł: A fork() in the road, HotOS 2019

sys execve: obsługa wywołania systemowego

Obraz procesu to skonfigurowana przestrzeń adresowa.

- Zatrzymujemy wszystkie wątki użytkownika w przestrzeni jądra <u>thread_single</u> (podobnie jak przy fork).
- Przygotowujemy argumenty przekazywane do obrazu procesu <u>image args</u> (w stronicowalnej pamięci jądra) za pomocą <u>exec copyin args</u>.
- Wołamy właściwą procedurę <u>do_execve</u>, która ładuje nowy obraz procesu i modyfikuje odpowiednio zasoby.
- Jeśli udało się utworzyć nowy obraz procesu, to <u>post_execve</u> każe starym wątkom popełnić wyjście przy powrocie do przestrzeni użytkownika i kasuje stary obraz procesu.

do execve: właściwa część ładowania obrazu

- 1. Wykrywa format pliku wykonywalnego (image activators):
 - a. plik interpretowany (#! aka shebang, albo <u>ELF(5)</u> z segmentem INTERP)
 → ładuje interpreter (/bin/sh i jemu przekazuje program i parametry),
 - b. plik wykonywalny (ELF o typie DYN lub EXEC)
- 2. Tworzy nową przestrzeń adresową:
 - a. tworzy stos i wrzuca na niego argv i envp, oraz auxiliary vector
- 3. Ładuje program:
 - a. odczytuje listę segmentów typu PT_LOAD
 - b. odwzorowuje w pamięć strony pliku wykonywalnego według informacji ze struktury elf64_phdr, tj. p_vaddr, p_filesz, p_memsz, p_align
 - c. jeśli ELF dla Linuksa to zmienia <u>sysentvec</u>
- 4. Zwalnia zasoby nieużywane przez proces.
- 5. Tworzy kontekst startowy na podstawie e_entry.

ELF: Nagłówek pliku wykonywalnego

```
# file /bin/sh
/bin/sh: ELF 64-bit LSB executable, x86-64, version 1 (FreeBSD),
dynamically linked, interpreter /libexec/ld-elf.so.1,
for FreeBSD 12.0 (1200086), FreeBSD-style, stripped
# readelf -h /bin/sh
ELF Header:
  OS/ABI:
                                      FreeBSD
  ABI Version:
  Type:
                                      EXEC (Executable file)
  Machine:
                                      Advanced Micro Devices x86-64
  Version:
                                      0x1
  Entry point address:
                                      0x20b000
```

ELF: Nagłówki segmentów pliku wykonywalnego

```
# readelf -l /bin/sh
Program Headers:
              Offset
                             VirtAddr
                                             PhysAddr
 Type
              FileSiz
                             MemSi<sub>7</sub>
                                              Flg
                                                    Align
 TNTFRP
              0x0000000000000015 0x0000000000000015
                                                    0x1
     [Requesting program interpreter: /libexec/ld-elf.so.1]
 LOAD
              0x00000000000000 0x00000000000002a0
                                                    0x1000
 LOAD
              0x000000000000b000 0x00000000020b000 0x0000000000020b000
              0x00000000001bc70 0x000000000001bc70
                                                    0x1000
 LOAD
              0x000000000027000 0x000000000227000 0x0000000000227000
              0x0000000000001190 0x00000000000033ac
                                              RW
                                                    0x1000
```

ELF: Konsolidator dynamiczny

```
# file /libexec/ld-elf.so.1
/libexec/ld-elf.so.1: ELF 64-bit LSB shared object, x86-64,
version 1 (FreeBSD), dynamically linked, stripped
# /libexec/ld-elf.so.1 -h
Usage: /libexec/ld-elf.so.1 [-h] [-f <FD>] [--] <binary> [<args>]
# procstat -v $$ | cut -f 2,3,4,11 -w
0x200000 0x20b000 r--/bin/sh
0x20b000 0x227000 r-x/bin/sh
0x227000 0x228000 rw-/bin/sh
0x800227000
              0x80022f000
                           r-- /libexec/ld-elf.so.1
0x80022f000
                           r-x /libexec/ld-elf.so.1
              0x800248000
0x800248000
              0x800249000
                           rw-/libexec/ld-elf.so.1
```

Sygnały, grupy, sesje

FreeBSD: Sygnaly

Sygnały są programowym odzwierciedleniem przerwań:

Hardware Machine	Software Virtual Machine
instruction set	set of system calls
restartable instructions	restartable system calls
interrupts/traps	signals
interrupt/trap handlers	signal handlers
blocking interrupts	masking signals
interrupt stack	signal stack

Wysłanie sygnału może się zakończyć:

- 1. Zignorowaniem go.
- 2. Zakończeniem wszystkich wątków w procesie.
- 3. Wstrzymaniem / wznowieniem wszystkich wątków.

Procedura obsługi sygnału

Ustawiana przez wywołanie <u>sigaction(2)</u> i przechowywana w p_sigacts. Wywoływana przez jądro w wyniku zdarzenia:

- programowego → np. naciśnięcie CTRL+C na klawiaturze
- sprzętowego → np. użycie nieznanej instrukcji

Za tłumaczenie zdarzeń sprzętowych na sygnały odpowiada procedura <u>trap</u> (MIPS).

NetBSD: Właściwości i domyślne akcje sygnałów

Tablica <u>sigprop</u> dla każdego sygnału przechowuje logiczną sumę:

```
SA_KILL : terminates process by default
```

SA_CORE : ditto and coredumps

SA_STOP : suspend process

SA_TTYSTOP: ditto, from tty

SA_IGNORE : ignore by default

SA_CONT : continue if suspended

SA_CANTMASK : non-maskable, catchable

SA_NORESET : not reset when caught

SA_TOLWP : to LWP that generated, if local

SA_TOALL : always to all LWPs

Pytanie: Jakie właściwości mają: SIGCHLD, SIGINT, SIGTRAP, SIGTSTP, SIGKILL, SIGSEGV, SIGSTOP, SIGCONT?

FreeBSD: Wysyłanie sygnału psignal(9)

1. Sygnały synchroniczne.

<u>trap</u> rejestruje błąd w <u>ksiginfo</u> i dostarcza sygnał <u>trapsignal</u>. Proces nieśledzony → sygnał dostarczony do wątku <u>tdsendsignal</u> bez opóźnienia, w p.p. skierowany do procesu śledzącego (gdb).

2. Sygnały asynchroniczne.

Sprawdzenie uprawnień <u>p_cansignal</u> (SIGCONT!).

Do procesu <u>kern_psignal</u>, a grupy <u>pgsignal</u>.

Sprawdza czy sygnał ignorowany p_sigignore,
czy wyłapywany p_sigcatch. Dodaje do listy sygnałów
oczekujących td_siglist i wybudza wątek, jeśli to możliwe.

Dostarczanie sygnału

Sygnały sprawdzane w <u>ast</u> przed powrotem do przestrzeni użytkownika i przed uśpieniem sleepq_wait_sig.

Przy wyznaczaniu sygnału do dostarczenia <u>issignal</u>, wątek sumuje oczekujące sygnały procesu <u>p sigqueue</u> i <u>td sigqueue</u>. Kiedy znamy już numer sygnału odznaczamy go w obu kolejkach.

W pętli odpytujemy <u>cursig</u> i dostarczamy je <u>postsig</u>, które:

- albo zabija proces → może utworzyć zrzut pamięci,
- 2. albo przygotowuje kontekst wątku, z użyciem <u>sendsig</u> (MD), na wejście do procedury obsługi sygnału; dodatkowo maskuje sygnał na czas obsługi.

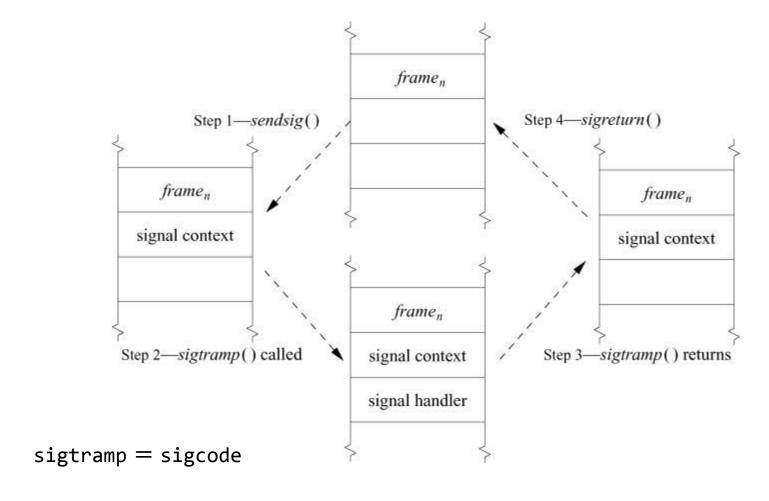
Obsługa sygnału

Procedura **sendsig** kopiuje na stos procedury obsługi sygnału (pożyczony od wątku użytkownika albo ustawiony <u>sigaltstack</u>):

- 1. Bieżący kontekst użytkownika <u>sigframe</u>.
- 2. Argumenty procedury obsługi sygnału.
- 3. Kod^{*}, którego zadaniem jest wywołanie procedury obsługi sygnału i wywołanie <u>sigreturn</u> po zakończeniu.

Zadaniem **sigreturn** jest atomowo odblokować sygnały i przywrócić kontekst ze stosu użytkownika.

Obsługa sygnałów



Dynamiczna biblioteka jądra

Jak w trybie użytkownika zawołać <u>sigcode</u>, skoro jednak stos nie jest wykonywalny? Na **amd64** ustawiamy **%rip** na <u>sigcode</u> umieszczony na współdzielonej stronie.

Na sam koniec przestrzeni adresowej <u>exec new vmspace</u> wrzuca odpowiednik linuksowego <u>vdso(8)</u>, czyli współdzieloną stronę z kodem i danymi przygotowaną przez <u>exec sysvec init</u>.

Oprócz sigcode trzymamy na niej procedury do odczytu czasu (<u>vdso gettimeofday</u>) dla biblioteki libc.

Czas aktualizowany w dogodnych dla jądra momentach, ale nie rzadziej niż co takt zegara systemowego.

Grupy procesów

Zarządzanie procesami zgrupowanymi w zadania (ang. jobs):

- 1. potoki w shell'u
- 2. wysyłanie sygnałów SIGSTOP, SIGCONT, SIGINT, ...

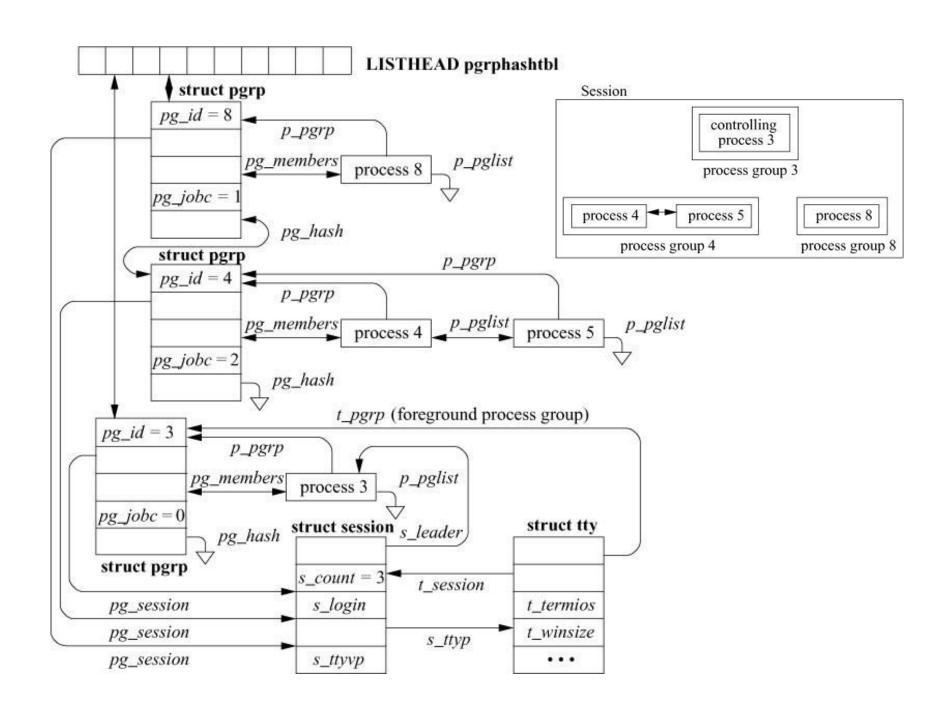
Każdy proces należy do dokładnie jednej grupy procesów pgrp zapisanej w pgrp! Identyfikator grupy pgid jest tożsamy z identyfikatorem pid procesu, który ją utworzył. Domyślnie grupa dziedziczona po rodzicu.

<u>setpgid</u>: proces może zmienić swoją grupę tworząc nową, albo zmienić grupę swoich procesów potomnych^{*}.

Sesje

Tworzona wraz z nową grupą procesów przy pomocy setsid(2).

- 1. Sesja może posiadać urządzenie terminala sterującego.
- 2. Lider sesji może ustanowić połączenie z terminalem
 → staje się wtedy procesem sterującym.
- 3. Grupy procesów dzielą się na **pierwszoplanowe** (ang. *foreground*) i **drugoplanowe** (ang. *background*).
- 4. Kody sterujące interpretowane przez urządzenie terminala (np. Ctrl+c, CTRL+\) są zamieniane na sygnały (SIGINT, SIGQUIT) i dostarczane do grupy pierwszoplanowej.
- 5. Tylko członkowie sesji są w stanie zmieniać przypisanie terminala sterujące do innej grupy procesów w obrębie sesji.



Problem z osieroconymi grupami procesów

Grupa procesów jest **osierocona**, jeśli żaden proces należący do tej grupy nie posiada rodzica, który należy do innej grupy w obrębie tej samej sesji.

Jeśli proces sterujący (np. powłoka) się zakończy, to system odbiera procesom w sesji dostęp do urządzenia terminala, a do grupy pierwszoplanowej wysyła SIGHUP. W grupach drugoplanowych nadal możemy zatrzymane procesy.

- Grupa pierwszoplanowa przechowywana w tty::<u>t pgrp</u>.
- Liczba potomków procesu sterującego w pgrp::pg_jobc.

Osieroconym grupom procesów jądro wysyła SIGHUP i SIGCONT. Zapobiega ponownemu wysyłaniu SIGTTIN i SIGTTOU.

Śledzenie procesów

Śledzenie wykonania procesów

```
int ptrace(int request, pid_t pid, caddr_t addr, int data);
Z użyciem wywołania ptrace można:
```

- podłączyć się do istniejącego procesu by go <u>odpluskwiać</u>
- czytać i modyfikować stan procesu (rejestry, pamięć)
- przechwytywać sygnały wysyłane do procesu
- nasłuchiwać na zdarzenia (fork, exec)
- śledzić wywołania systemowe
- przełączyć wykonywanie programu w tryb krokowy

Śledzenie wywołań systemowych z użyciem narzędzia <u>strace</u> (Linux) lub <u>truss</u> (FreeBSD)!

Debugowanie procesu

Śledzenie (ang. tracing) i instrukcje breakpoint → SIGTRAP.

- Debugowany proces zamiast odbierać sygnał, zostaje zatrzymany (stan STOPPED).
- 2. Debugger zostaje poinformowany SIGCHLD.
- 3. Debugger sprawdza stan procesu wywołaniem wait6(2).
- 4. Podjęcie decyzji o debugowanym procesie:
 - a. PT_CONTINUE: wznawia pracę pod zadanym adresem i ew. dostarcza sygnał o podanym numerze
 - b. PT_STEP: j.w. ale w trybie krokowym
 - c. PT_KILL: PT_CONTINUE + SIGKILL

Startowanie sesji debugowej

Można się podłączyć do istniejącego procesu: **PT_ATTACH**. Co jeśli chcemy zatrzymać się na pierwszej instrukcji?

- 1. Debugger tworzy dziecko.
- 2. Te oznacza się flagą <u>P_TRACED</u> przy użyciu PT_TRACE_ME.
- 3. Woła execve(2) ze ścieżką do pliku wykonywalnego.
- 4. Jądro po załadowaniu obrazu wysyła SIGTRAP.

Możemy odłączyć się od debugowanego procesu PT_DETACH.

Dostęp do danych debugowanego procesu

- 1. Odczyt i zapis rejestrów: PT_GETREGS, PT_SETREGS
- 2. Pojedyńcze słowa maszynowe: PT_READ_*, PT_WRITE_*
- 3. Kopiowanie pamięci: PT_IO
- 4. Odczyt stanu procesu: PT_LWPINFO, ...

W przypadku kopiowania dużych ilości pamięci z / do debugowanego procesu PT_IO niewydajne!

Z pomocą przychodzi system plików / proc!

Oprócz tych samych funkcji co **ptrace**, umożliwa odwzorowanie przestrzeni adresowej debugowanego procesu (**/proc/pid/map**) przy użyciu <u>mmap(2)</u>.

Pytania?