
Systemy operacyjne

Wykład 15 Architektura jądra SO

Pierwotna struktura jądra

Górna i dolna połowa jądra



Podział niezależny od stopnia złożoności jądra. Reakcje na zdarzenia zewnętrzne i wykonywanie instrukcji programów żyją w różnych światach, a muszą się komunikować!

Dolna połówka

Dolna połówka asynchroniczna względem górnej połówki. Wykonuje kod obsługi przerwań. Informuje **górną połówkę** o pojawieniu się zdarzeń (np. koniec transmisji), które wznawiają wykonanie funkcji na rzecz programu użytkownika.

Nie może zatrzymać się nieokreśloną ilość czasu. Dlaczego?

Dolna połówka ma "wyższy priorytet". W każdej chwili może przerwać działanie górnej połówki jeśli włączone przerwania.

Przypomnienie: Wyłączanie przerwań to instrukcja uprzywilejowana!

Pytanie: Co jeśli przerwania sprzętowe mają priorytety?

Górna połówka

Wielozadaniowość kooperacyjna – jeśli zadanie nie potrzebuje już procesora (np. czeka na przyjście zdarzenia) to woła planistę celem przełączenia na inne zadanie.

Górna połówka reprezentuje funkcje jądra wykonywane na rzecz programów użytkownika. Jeśli wiele programów, to każdy ma przypisany **kontekst** jądra. Przełączanie programów następuje w sposób kooperacyjny.

Narzędzia do zachowywania i wznawiania kontekstów: kanały oczekiwania, muteksy, skrzynki pocztowe, ...

Wywłaszczalne jądro SO

Wywłaszczanie (ang. *preemption*) to odebranie zasobu programowi bez wpływu na jego poprawność.

Pojęcie najczęściej odnosi się do czasu procesora. Oznacza **przełączenie kontekstu** w wyniku zdarzenia zewnętrznego – np. upłynięcia **kwantu czasu**.

Jądro jest wywłaszczalne, jeśli w wyniku przerwań sprzętowych potrafi przełączać się między wykonywaniem funkcji na rzecz różnych procesów użytkownika.


Pytanie: Czemu jest to pożądana cecha?

Gdzie wykonuje się kod jądra?


- a. odrębna przestrzeń adresowa (wczesne SO dla PC)
- b. jądra monolityczne
- c. mikrojądra

<u>Unikernels</u>: jądro i program żyją w tej samej przestrzeni adresowej.


SO dla systemów wbudowanych również uruchamiają programy w tej samej przestrzeni adresowej.



(a) Separate kernel




(b) OS functions execute within user processes



(c) OS functions execute as separate processes

Obsługa wywołania systemowego we FreeBSD

- zapisanie kontekstu
- obsługa pułapki
- wektor wywołań systemowych
- copyin
- weryfikacja argumentów
- obsługa wywołania
- copyout
- ustawienie <u>errno</u>
- <u>userret</u>
- odtworzenie kontekstu
- powrót z pułapki



Architektura jądra


MS-DOS: Struktura ad-hoc

Podstawowe funkcje z minimalnym narzutem pamięciowym (min. 64K).

Wywołania systemowe dostarczone przez BIOS, interpreter poleceń, sterowniki i dodatkowe programy.

Brak izolacji, programy wykorzystują wiedzę o strukturach danych jądra.

Brak modularności, awaryjność.




Unix: jądro monolityczne

Wymaga ochrony pamięci i trybu uprzywilejowanego. Błąd w jądrze kończy się załamaniem systemu.

Pierwotnie niewywłaszczalne.

Struktura modularna z elementami warstwowości.

Nierozszerzalne? Późniejsze systemy unikso-podobne dodają moduły i konsolidator jądra.




Struktura warstwowa

System operacyjny podzielony na warstwy, każda nadbudowana na niższej.

Dzięki odpowiedniemu zaprojektowaniu (modularność),warstwy korzystają tylko z funkcji warstw niżej.


W jądrze monolitycznym dużo większa pokusa, żeby łamać warstwowość celem optymalizacji!

Wyidealizowany obraz rzeczywistości!



Linux kernel map functionalities human interface system processing storage networking memory layers interfaces core processes memory access HI char devices files & directories sockets access sys fork user sys brk System Call Interface system files svs kill sys_vfork sys socketcall svs open sys_mmap shm_vm_ops sys_pivot_root sys signal linux/syscalls.h svs clone sys read svs socket /proc /sysfs /dev do_sigaction sys_shmctl sys_connect space sys_tee sys_poll sys_write linux/uaccess.h sys_shmat sys_pipe sys_select do_path_colup getdents sys_flock sys_readv sys_ reclevely.ee lovec sys sysfs ops copy_from_user sys_bind /proc/net/ interfaces linux binfmt sys_splice sys_sendfile svs listen si_meminfo svs futex tcp4 sea show snd fops sys ioctl svs sendmsa sys_mincore video fons sys_time sys_chown sys_chino notify_change sa proc sea show dev cdev add svs recvmsq system calls /dev/mem console fops sys times and system files svs setsockop rt cache seg show cdev_map sys_epoll_create mem fops sys_capset fb_fops /proc/meminfo sys reboot sys syslog svs msvnc sock joctl /proc/self/maps threads virtual memory Virtual File System protocol families **Device Model** vfs fsync security security vmalloc init queue_work INIT WORK / find vma prepare vfs_write vfs_create linux/kobiect.h vfs_getattr inet_family_ops security_capset may_open work struct kset linux/device.h virtual inet create inode vmalloc unix_family_ops kthread create inode operations kernel thread device_create proto_ops security ops vm_struct file_system_type current do fork thread info inet_dgram_ops inet stream ops device type virt_to_page super block generic file aid do splice direct socket_file_ops driver register ramfs fs type memory do_mmap debugging synchronization device_driver page cache networking socket lock kernel mapping splice bridges svs ptrace log buf probe storage nfs file operations add_timer do_mmap_pgoff cross-functional modules down interruptible si_swapinfo top sendpage timer_list run timer softirq kmem cache alloc smb fs type module kobiect uevent init udp sendpage handle sysrq oprofile start vma link swap info kswapd wait event cifs file ops module_param kobiect uevent mm struct sock splice read wake up do_swap_page kadb breakpoint oprofile init spin_lock_irqsave iscsi_tcp_transport tcp splice read kernel_param wakeup kswapd Scheduler protocols HI subsystems logical memory logical system run boot, shutdown physically mapped memor file systems tcp prot task struct logical usp sendmsg tcp_v4_rcv alsa ext4 file operations functions schedule_timeout_ udp rcv kmalloc schedule implementations do_initcalls video_device ext4_get_sb kfree ip queue xmit pgd_t pmd_t pte_t ext4 readdir run init process kernel power off process timeour ip push pending frames context switch machine ops ip_rcv sk buff abstract devices generic HW access interrupts core Page Allocator block devices network interface and aendisk request region HID class drivers _free_pages dev queue xmit block_device_operations device pci register driver jiffies 64++ kmem cache free one page pci_request_regions net_device control kmem cache alloc scsi_device setup_irq tick_periodic get_free_pages sosi driver kbd usb_submit_urb timer interrupt sd fops fb_ops do_softirq usb hod giveback urb do IRQ irq desc usb storage drive vm stat mousedev usb hcd totalram_pages try_to_free_pages drm driver softirq_init CPU specific HI peripherals device access physical memory disk controller network device drivers and bus drivers operations drivers device drivers hardware uvc driver arch/x86/mm/ get_page_from_freelist ac97 driver interfaces native init IRQ switch to vga cor scsi host alloc ipw2100 pci init one atkbd dry zd1201 probe free area free list drivers, registers and interrupts usb hcd irq e1000_xmit_frame i8042 driver out_of_memory die ahci pci driver show_regs interrunt e1000_intr aic94xx init pt_regs atomic_t pci write do_page_fault num_physpages user peripherals 1/O mem 1/O CPU network controllers disk controllers memory electronics graphics card

Mikrojądro




W jądrze minimalny zestaw funkcji. Usługi, sterowniki, systemy plików – działają na tych samych zasadach co programu użytkownika. Można je restartować – serwer reinkarnacji Minix 3.

IPC z użyciem przekazywania komunikatów

Jądro tylko pośredniczy w wymianie komunikatów między serwerami usług.

Izolacja między usługami polepsza niezawodność i elastyczność systemu



Koszt? Więcej kopiowania danych. Większa liczba zmiany kontekstów. Tylko małe komunikaty można kopiować efektywnie! Co zrobić z dużymi?

Mniejsza wydajność niż jądra monolityczne. Trudności pokonane, ale niesmak pozostał → jądra hybrydowe. Za to L4 się udało!

Windows NT: jądro hybrydowe


Zmiana kontekstu zbyt droga. Krytyczne wydajnościowo komponenty w jądrze.

Kod jądra wykonuje się poza kontekstem wątków jądrowych.

HAL unifikuje dostęp do części zasobów sprzętowych.


Windows Executive dostarcza podstawowych usług dla programów użytkownika.

Osobowości: Win32, POSIX.



Exokernel

Abstrakcje powodują spadek wydajności. Interfejs jądra powinien być dostosowany do wymagań aplikacji.



Egzojądro nie zarządza zasobami! Dba jedynie o bezpieczne dzielenie zasobów między aplikacjami.

System operacyjny udostępnia zestaw bibliotek (libOS) realizujących różne warstwy abstrakcji. Każda aplikacja wybiera sobie czego potrzebuje.

Unikernel szczególnym przypadek architektury exokernel.

Mikrojądro L4

Wprowadzenie do L4

Małe (< 10kLOC)! Bardzo szybki mechanizm komunikacji. Nie ma planisty zadań ani zarządzania pamięcią!

- wątki
- przestrzeni adresowe
- zadania (grupowanie wątków)
- komunikacja międzyprocesowa

Wątek posiada zestaw wirtualnych rejestrów (**TCR**, **MR**, **BR**), do komunikacji z μ-jądrem i innymi wątkami. Rozbudowany protokół komunikacji z jądrem.

Komunikacja w L4

Jądro niewywłaszczalne poza ustalonymi punktami. Przesyłanie komunikatów blokujące → schadzki / randki (ang. *rednez-vous*).

Komunikat składa się: z nagłówka, pewnej liczby *untyped word* i *typed word*, co wpisujemy do *Message Registers*. Żeby odebrać należy przygotować miejsce i poinformować jądro przez wypełnienie *Buffer Registers*.

Elementy o ustalonym znaczeniu:

- StringItem ciąg bajtów kopiowany przez jądro do odbiorcy
- MapItem wysłanie stron z zachowaniem prawa własności
- GrantItem przekazanie praw własności do stron

Protokoły L4


Zestaw specjalnych komunikatów jądra:

- ThreadStart początkowe PC i SP wątku
- Interrupt koduje zgłoszenie i obsłużenia przerwania
- PageFault informuje program stronicujący o błędzie strony wątku i pozwala podłączyć brakującą stronę
- Preemption zgłasza wywłaszczenie wątku programowi planisty
- Exception zgłasza powstanie wyjątku procesora w zadanym wątku i pozwala na wznowienie jego wykonania
- σ₀ obsługa początkowej przestrzeni adresowej

Planista o obsługa błędów stron w L4

Każdy wątek X ma przypisany wątek:

- planisty S, który wysyła informacje do jądra na ile czasu uruchomić wątek X,
- programu stronicującego P, który obsługuje błędy stron dla wątku X.



Pytania?